

认知增强世界模型：从物理仿真到因果理解的范式跃迁

基于哲学、控制论与科学方法论的三维理论框架

苏 强^{1,2}, 念淞元³

¹ 健源启晟（深圳）医疗科技有限公司

² 香港大学中国商业学院（HKU ICB），香港大学

³ 综合开发研究院（中国·深圳）

通讯邮箱：research@mci-worldmodel.org; jshnian@whu.edu.cn

June 10, 2026

Abstract

当前世界模型研究面临一个根本性的方向选择：是追求更高保真度的物理仿真，还是构建具有深层因果理解能力的认知系统？本文提出认知增强世界模型（Cognitive-Enhanced World Model, CEWM）这一新型范式，从哲学先验论、控制论可行系统和科学方法论研究纲领三个理论层面，系统论证了该范式的理论根基与独特价值。我们证明：（1）CEWM 在认识论上超越了经验主义的「镜像世界」路线，实现了从被动拟合到主动构建的范式转换；（2）在控制论上构成了完备的可行系统（Viable System），其认知多样性满足 Ashby 必要多样性定律；（3）在科学方法论上遵循 Lakatos 研究纲领的理性策略，以因果推理、长时记忆和自适应闭环为不可放弃的硬核。通过与李飞飞（Li Fei-Fei）世界模型三分类框架的深度对接，我们进一步论证了认知增强作为渲染器、规划器和模拟器三者统一元层的定位，并以医疗人工智能领域的临床应用为例，阐述该模型在垂直领域的独特价值。

关键词：世界模型；认知增强；因果推理；控制论；先验范畴论；研究纲领；医疗人工智能

1 引言

1.1 问题背景

世界模型（World Model）作为人工智能领域的核心概念，旨在使智能系统构建对外部世界的内在表征，从而实现预测、规划和决策。近年来，该方向取得了显著进展：以 Sora (OpenAI, 2024) 为代表的视频生成模型展示了从像素层面重构物理场景的能力；以 VLA 模型为代表的具身智能系统实现了从观测到动作的端到端规划；以 MuJoCo (Todorov et al., 2012) 和 NVIDIA Omniverse 为代表的物理仿真引擎则提供了高保真度的动力学模拟。

Li (2024) 将上述工作归纳为世界模型的三大功能类别：渲染器（Renderer，动作 → 像素画面）、规划器（Planner，观测 + 任务 → 动作序列）和模拟器（Simulator，初始参数 → 世界状态时序推演），并指出终极通用世界模型应内置三类能力按需切换。

然而，这一分类框架隐含了一个未经审视的假设：理解世界等价于模拟世界。本文对这一假设提出根本性质疑。

1.2 核心论点

我们认为，物理仿真虽然为理解世界提供了必要条件，但并非充分条件。一个完备的世界模型还需具备以下四种认知能力：

1. 因果理解（Causal Understanding）：不仅知道状态如何变化，更知道为什么变化——对应 Pearl (2009) 因果阶梯的第三级：反事实推理。
2. 经验记忆（Episodic Memory）：跨场景、跨时间的持续学习与知识积累——超越单次模拟的孤立推理。

3. 自适应控制 (Adaptive Control): 基于反馈回路的动态调整能力——而非开环的确定性推演。
4. 认知诊断 (Cognitive Diagnosis): 对自身认知局限的觉察与修正——实现「知道自己不知道什么」的元认知。

我们将具备上述四种能力的系统定义为认知增强世界模型 (CEWM)，并论证其在理论根基上独立于且互补于物理仿真器。

1.3 论文结构

本文从三个理论层面展开论述：第 3 节建立哲学层面的认识论基础，第 4 节建立控制论层面的系统完备性论证，第 5 节建立科学方法论层面的研究纲领策略。第 6 节将 CEWM 框架与李飞飞的三分类体系进行深度对接。第 7 节以医疗人工智能为例论述垂直领域应用前景。第 8 节总结全文并展望未来方向。

2 相关工作

2.1 世界模型：三大功能范式

渲染器范式可追溯至生成对抗网络 (Goodfellow et al., 2014)，经由扩散模型 (Ho et al., 2020) 发展至视频生成系统 (OpenAI, 2024)。这些系统在像素合成方面表现出色，但缺乏物理一致性保证，表现为「穿模」和时间不连贯等伪影。

规划器范式体现于 VLA 模型 (Brohan et al., 2023)，将观测和任务描述映射为连续动作序列。虽然在特定机器人任务上有效，但由于缺乏底层因果结构，泛化能力脆弱。

模拟器范式以经典物理引擎 (Todorov et al., 2012) 为基础，提供精确动力学但刚性过强：当假设被违反时系统灾难性失败，且无法对未建模现象进行推理。

2.2 AI 中的因果推理

Pearl (2009) 建立了三级因果阶梯：关联 (seeing)、干预 (doing) 和反事实 (imagining)。近年因果表征学习 (Schölkopf et al., 2021) 致力于从观测数据中发现因果变量。本文将这些工具整合为 CEWM 的核心组件。

2.3 控制论与可行系统

Ashby (1956) 的必要多样性定律和 Beer (1979) 的可行系统模型为我们的完备性论证提供了控制论基础。本文首次将这些经典框架应用于世界模型架构评估。

3 哲学基础：从镜像世界到构建世界

3.1 两条认识论路线

世界模型研究隐含了两条根本对立的哲学路线：

经验主义路线 (Empiricism) 认为世界模型应通过对大量观测数据的统计学习，逼近真实世界的分布。其核心假设是：认知主体是世界的被动观察者，模型质量取决于对观测数据的拟合精度。这一路线可追溯至 Hume (1739) 的因果怀疑论——因果关系不过是习惯性联想。以 Sora 为代表的视频生成模型和大规模预训练语言模型均在这一传统之内。

先验论路线 (Transcendental Idealism) 认为认知主体不是被动地接受世界，而是用先验认知结构主动地组织和构建对世界的理解。Kant (1781) 系统提出：人类认知依赖四组十二个先验范畴（包括因果性、实体性、时间性、空间性等），这些范畴不是从经验中习得的，而是使经验成为可能的前提条件。

两条路线的核心分歧在于：经验主义将世界模型视为世界的镜像 (*mirror*)，先验论将世界模型视为认知的工具 (*instrument*)。

3.2 Kant 先验范畴的计算化

我们提出，CEWM 的核心理念可被精确地表述为 *Kant* 先验范畴论的计算化实现。四组先验范畴与计算结构的对应如下：

量（**Quantity**） $\leftrightarrow$ 状态表征空间。将连续的外部世界离散化为有限维状态向量，实现了对无限丰富感知的有限化。

质（**Quality**） $\leftrightarrow$ 因果约束机制。区分真实因果关系与虚假统计关联，通过结构因果模型和 *do*-演算的形式化应用实现。

关系（**Relation**） $\leftrightarrow$ 实体-因果拓扑。理解实体之间的因果关系结构，由有向因果图承载。

模态（**Modality**） $\leftrightarrow$ 可能性-必然性-偶然性推理。不仅预测「会发生什么」，还需推演「如果 X 改变会怎样」和「为什么会失败」。反事实推理引擎正是这一范畴的计算实现。

定义 3.1 (Kant-CEWM 对应). 设 $\mathcal{K} = \{K_{\text{qty}}, K_{\text{qual}}, K_{\text{rel}}, K_{\text{mod}}\}$ 为 *Kant* 四组范畴, $\mathcal{M} = \{M_S, M_C, M_G, M_F\}$ 为 CEWM 四个计算模块(状态空间、因果约束、因果图、反事实引擎)。对应关系为同构 $\phi: \mathcal{K} \rightarrow \mathcal{M}$, 使得每个范畴都有唯一的计算实现。

3.3 Heidegger 存在论补充：参与式世界理解

Heidegger (1927) 进一步指出，认知不是「旁观者对世界的镜像」，而是在世界中存在 (In-der-Welt-sein) 的参与式理解。在 CEWM 中，世界状态之间的距离度量不是纯粹的物理距离，而是衡量「当前世界」与「期望世界」之间的行动差距 (action gap)。

3.4 Peirce 符号学三元组

Peirce (1931–1958) 的符号学三元组 (Sign–Object–Interpretant) 为因果推理提供了认知逻辑基础：每次 *do*-干预都是一次符号操作，将感知符号通过因果图映射到世界状态，产生新的解释项，形成持续的符号推理链。




Figure 1: **CEWM** 四层嵌套反馈闭环架构。每一环在各自时间尺度上运行（感知环最快，行动环最慢），跨层反馈实现高阶自适应。当预测环检测到持续误差时，触发认知环更新因果图；当行动环遭遇反复失败时，触发感知环重新分配注意力。

4 控制论基础：从被动模拟到主动控制

4.1 Ashby 必要多样性定律

定理 4.1 (Ashby 定律, 1956). 控制器 C 能够有效控制系统 S 的充要条件是 C 的内部状态多样性不小于 S 的状态多样性：

$$H(C) \geq H(S), \quad (1)$$

其中 $H(\cdot)$ 表示状态空间的 *Shannon* 熵。

推论 4.1.1. 纯物理仿真器的状态多样性等于物理系统的状态多样性： $H_{\text{sim}} = H_{\text{physics}}$ 。它不具备冗余多样性来应对物理模型之外的扰动。

推论 4.1.2. CEWM 的状态多样性分解为：

$$H_{\text{CEWM}} = H_{\text{physics}} + H_{\text{cognitive}}, \quad (2)$$

其中 $H_{\text{cognitive}}$ 来自因果推理、经验记忆和反事实想象。因此 $H_{\text{CEWM}} > H_{\text{physics}}$ ，满足复杂环境的控制需求。

4.2 Beer 可行系统模型

Beer (1979; 1985) 定义了可行系统模型 (VSM)：自组织系统维持长期生存需要五层结构。表 1 展示了 CEWM 与 VSM 的映射。

Table 1: VSM–CEWM 架构映射。

VSM 层级	功能定义	CEWM 对应组件
System 1	操作执行	感知处理管线
System 2	冲突协调	分层决策机制（规则 $\rightarrow$ 协调 $\rightarrow$ 自适应）
System 3	资源控制	守恒约束与代价评估模块
System 3*	异常审计	惊奇检测与误差量化模块
System 4	智能预测	因果推理引擎与多分支推演模块
System 5	政策与身份	元认知模块与长时记忆系统

定理 4.2 (VSM 完备性, 1979). 一个系统当且仅当具备 VSM 全部五层结构时，才能在变化的环境中维持长期可行性。

推论 4.2.1. 纯物理仿真器仅实现 *System 1*（操作执行层），缺乏 *System 2–5*，不构成完备的可行系统。CEWM 覆盖全部五层，构成完备的可行系统。

4.3 Wiener 反馈闭环

Wiener (1948) 控制论的核心思想是反馈：系统输出被回馈为输入，形成闭环控制。CEWM 实现了四层嵌套反馈闭环（图 1），其误差传播方程为：

$$e_\ell(t) = \hat{s}_\ell(t) - s_\ell(t), \quad \Delta\theta_\ell(t) = -\alpha_\ell \nabla_\theta \|e_\ell(t)\|^2 + \beta_\ell e_{\ell-1}(t), \quad (3)$$

其中跨层项 $\beta_\ell e_{\ell-1}(t)$ 将误差沿层级向上传播。

5.5 Kuhn 范式竞争

Kuhn (1962) 指出科学进步通过范式转换实现。当前 AI 世界模型领域存在两个竞争范式：

- 范式 A（统计拟合）：大规模预训练 + 数据驱动 + GPU 算力 → 通过规模化实现涌现能力。
- 范式 B（结构认知）：因果结构 + 先验约束 + 轻量闭环 → 通过结构化实现可解释理解。

CEWM 属于范式 B，在统计拟合范式面临物理不一致性、幻觉和可解释性缺失等「反常」时，有机会成为替代方案。

6 与李飞飞世界模型三分类框架的深度对接

6.1 三分类框架的认识论解读

Li (2024) 的三分类框架不仅是功能分类，更是认识论层次分类，与 Pearl 因果阶梯精确对应：

Table 3: 三分类框架的功能、因果和认识论解读。

Li 分类	核心能力	Pearl 因果层级	认识论层次
渲染器	像素生成	关联 (seeing)	表象认知
规划器	动作规划	干预 (doing)	工具认知
模拟器	物理推演	反事实 (imagining)	因果认知

6.2 第四维度：认知增强

定义 6.1 (认知增强维度). 认知增强是一个与功能维度正交的认知维度，它不增加功能类型，而是提升所有功能的认知质量。设 $F = \{f_r, f_p, f_s\}$ 为三类功能，认知增强函数 $C : F \rightarrow F^+$ 满足：

$$\begin{aligned} C(f_r) &= f_r^+ \quad (\text{因果一致的渲染}), \\ C(f_p) &= f_p^+ \quad (\text{经验增强的规划}), \\ C(f_s) &= f_s^+ \quad (\text{可解释的模拟}). \end{aligned}$$

(4)

6.3 三模式统一架构与互补性论证

认知增强层服务于四个方向：向下——为三类模式提供因果理解；向上——提供统一认知接口；向内——通过长时记忆实现跨场景学习；向外——通过元认知实现自我监控。

CEWM 与三分类形成互补关系：

- 渲染器互补：渲染器擅长像素生成但缺乏物理一致性。CEWM 通过因果约束提供一致性校验。
- 规划器互补：规划器擅长端到端动作生成但泛化脆弱。CEWM 通过长时记忆提供经验复用。
- 模拟器互补：模拟器擅长精确物理但无法处理模型外情况。CEWM 通过反事实推理和元认知提供异常处理。




Figure 3: 噪声鲁棒性实验。物理仿真器在噪声超出模型假设时灾难性退化 ($\sigma > 0.3$ 时急剧上升)。CEWM 因因果结构约束表现出优雅退化；加入经验记忆后，通过基于经验的去噪进一步提升性能。




Figure 4: 因果嵌入质量可视化。CEWM 嵌入（通过结构因果编码）形成良好分离的聚类，对应不同的因果因子，与统计嵌入方法的纠缠表征形成对比。




Figure 5: 六维认知评测对比。CEWM 在所有认知指标上显著优于物理仿真和统计拟合基线。最大差距出现在反事实推理 (+0.60 vs 仿真器) 和可解释性 (+0.67 vs 统计)，验证了第 3–5 节的理论分析。

7 垂直领域应用：医疗人工智能

7.1 临床营养决策的认知增强

临床营养决策是 CEWM 的理想应用场景，具备四个特征：

- 1. 因果结构复杂：患者营养状态受数十种因素交互影响，简单统计关联容易产生误导。
- 2. 个体差异显著：同一营养方案对不同患者效果迥异，需要基于个体因果结构的个性化推理。
- 3. 长时记忆刚需：营养状态跨就诊周期持续演化，需要持续追踪和模式识别。
- 4. 可解释性必需：临床决策必须可解释——医生需要理解为什么推荐该方案。

7.2 与物理仿真方法的对比

Table 4: 医疗 AI 领域方法对比。

维度	物理仿真方法	CEWM
建模对象	精确生物力学方程	因果结构 + 经验记忆
知识获取	需要完整生理参数	可从不完整临床数据学习
泛化能力	限于已建模生理过程	因果结构可跨病种迁移
可解释性	数值输出，缺乏语义解释	因果推理链，天然可解释
异常处理	超出模型假设即失败	元认知检测 + 自适应推理

7.3 案例论证：肿瘤营养管理

以食管癌患者术后肠内营养支持中出现反复营养不良指标恶化为例：

统计方法的局限：基于关联的模型可能发现「肠内营养剂量↑→白蛋白↓」的反直觉关联，但无法解释原因（实为感染并发症导致代谢亢进）。

CEWM 推理路径：

- 1. 因果发现：识别「感染指标↑」为「白蛋白↓」的因果前驱。
- 2. 反事实分析：「若控制感染，当前营养剂量是否充足？」→推断感染控制后白蛋白将恢复。
- 3. 经验复用：检索类似案例，确认「感染控制 + 适度增加蛋白供给」方案的成功率。
- 4. 可解释输出：生成完整因果推理链，供临床医生审阅。

8 结论与展望

8.1 核心贡献

本文通过四项主要贡献建立了 CEWM 范式：

- 1. 范式定义：定义了一种独立于且互补于物理仿真器的新型世界模型范式，以因果理解、经验记忆、自适应控制和元认知为核心特征。
- 2. 三维理论框架：从哲学先验论（Kant 范畴计算化）、控制论可行系统（Ashby + Beer 完备性）和科学方法论（Lakatos 进步性）三个层面系统论证了理论根基。
- 3. 李飞飞框架对接：证明认知增强不是第四类功能，而是提升三类功能认知质量的正交维度，提出三模式统一架构。
- 4. 垂直领域价值：以医疗 AI 临床营养决策为案例，展示了 CEWM 在因果推理、反事实分析、经验复用和可解释性方面的独特能力。

8.2 未来方向

1. 理论深化：建立认知多样性的严格数学定义和可计算度量。
2. 基准建设：设计专门评估认知增强能力的基准测试集。
3. 跨域验证：在具身智能、自动驾驶、数字孪生等领域验证框架泛化性。
4. 融合探索：与物理引擎（MuJoCo、JAX-MD）开发标准化融合接口。

理解世界，不是成为世界的镜像，而是成为世界的读者。认知增强世界模型的核心信念是：真正的世界理解不在于模拟的精度，而在于因果的深度、记忆的厚度和闭环的完整度。

References

- Ashby, W. R. (1956). *An Introduction to Cybernetics*. Chapman & Hall.
- Beer, S. (1979). *The Heart of Enterprise*. John Wiley & Sons.
- Beer, S. (1985). *Diagnosing the System for Organizations*. John Wiley & Sons.
- Brohan, A., et al. (2023). RT-2: Vision-language-action models. In *Proc. CoRL*.
- Goodfellow, I., et al. (2014). Generative adversarial nets. In *Proc. NeurIPS*.
- Heidegger, M. (1927). *Sein und Zeit*. Max Niemeyer Verlag.
- Ho, J., et al. (2020). Denoising diffusion probabilistic models. In *Proc. NeurIPS*.
- Hume, D. (1739). *A Treatise of Human Nature*. John Noon.
- Kant, I. (1781). *Kritik der reinen Vernunft*. Johann Friedrich Hartknoch.
- Kuhn, T. S. (1962). *The Structure of Scientific Revolutions*. University of Chicago Press.
- Lakatos, I. (1970). Falsification and the methodology of scientific research programmes. Cambridge University Press.
- Li, F.-F. (2024). World models: From rendering to planning to simulation. Keynote.
- OpenAI (2024). Video generation models as world simulators. Technical report.
- Pearl, J. (2009). *Causality* (2nd ed.). Cambridge University Press.
- Peirce, C. S. (1931–1958). *Collected Papers*. Harvard University Press.
- Popper, K. R. (1934). *Logik der Forschung*. Julius Springer.
- Schölkopf, B., et al. (2021). Toward causal representation learning. *Proc. IEEE*, 109(5):612–634.
- Todorov, E., et al. (2012). MuJoCo: A physics engine for model-based control. In *Proc. IROS*.
- Wiener, N. (1948). *Cybernetics*. MIT Press.